Beyond Timestamps: Decision-Aligned On-Policy Distillation for Long-Horizon Agents

AlignOPSD：先对齐决策，再分配信用

Mingju Chen, Can Lv et al. · arXiv:2609.33391v1 · 2026

背景

密集反馈不一定是正确的反馈。 长程智能体需要把最终成败分配给中间决策；AlignOPSD 同时对齐教师证据的语境和信用分配的时间范围。

长程任务为何难以学习

家务控制、检索问答和在线购物都要完成一串相互依赖的动作，奖励却往往只在任务结束时出现。成功轨迹中可能包含无效行为，失败轨迹中也可能包含正确决策。

GRPO 将整条轨迹的优势广播给所有生成 token，难以定位具体贡献。OPSD 则让同一策略读取训练期特权信息，为学生自己生成的响应提供更密集的反馈。

两种“决策—时间戳”错位

跨轨迹错位： 同一时刻，学生可能还在比较商品，教师已在核对规格；对应的比较决策可能出现在另一时刻。特权信息也会改变教师当下想做的事。

轨迹内连续性： 一次收集证据或比较选项可能持续多轮。逐轮独立分配会切碎同一决策，固定窗口又可能混入不同决策。

图 1 • 决策不能只靠时刻定位

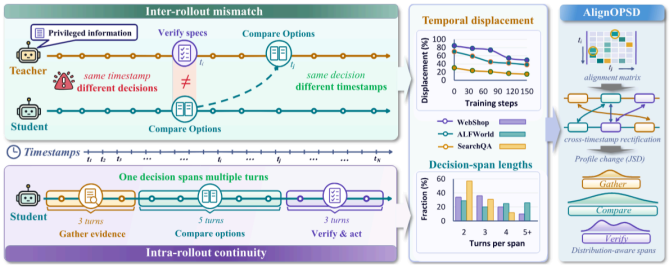


图 1：跨轨迹时间错位与多轮决策连续性。

左侧展示跨轨迹的时间位移与轨迹内的多轮决策；右侧用对应矩阵寻找匹配语境，再按对应关系的变化划分决策跨度。

相关工作

本文的差异是先建立跨轨迹功能对应，再形成细粒度信用；它同时改进“用什么证据评价”和“把哪些轮次视为一个决策”。

从自蒸馏到可比较的教师语境

OPSD 用同一策略的普通视图和特权视图评价学生行为，部署时移除特权输入。已有工作通过事后技能、同伴轨迹、可靠性估计等增强监督。

这些方法通常仍在目标自身的局部历史中评分，或把同伴轨迹作为整体上下文。AlignOPSD 显式检索功能对应的决策语境，并在这些语境中重新评价同一个学生响应。

从固定粒度到决策跨度

StepOPSD 采用动作中心的 step；GEAR 根据当前轨迹上的特权分歧变化划区域。AlignOPSD 用跨轨迹对应分布的变化确定边界，再在跨度之间、跨度内部两层分配信用。

这里并非否定同前缀概率比较的有效性，而是指出：这种分歧未必能单独衡量学生当前功能决策的好坏。

方法

训练分为两阶段：用同任务其他轨迹修正局部教师证据，再把结果优势分配到可变长度决策跨度及其内部轮次。部署时不需要这些辅助过程。

图 2 • 对齐监督与分层分配

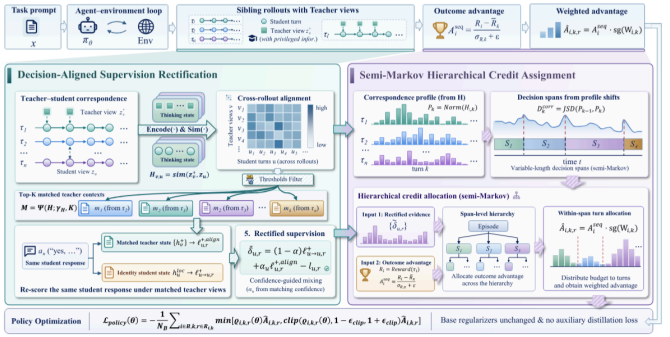


图 2：跨轨迹证据对齐、决策跨度与分层信用分配。

同一任务采样多个 sibling rollout，最终奖励确定更新方向。对应关系提供修正证据与分段依据，所得轮次权重进入原有策略优化目标。

方法

同一模型，两种条件视图

轨迹 i 的第 k 轮根据交互历史生成响应，环境返回观察。教师与学生共享参数；教师额外读取相关性检索得到的任务特权信息，且仅在训练时使用。

同任务一组轨迹的终局奖励用于构造组相对优势。均值与标准差均在该任务的 sibling rollouts 中计算。

$$A_i^{\text{seq}} = \frac{R_i - \overline{R}_x}{\widehat{\sigma}_{R,x} + \epsilon}, \qquad \overline{R}_x = \frac{1}{G}\sum_{j \in \mathcal{G}_x} R_j$$

R_i 为终局可验证奖励，G 为同任务轨迹数。正负优势决定更新方向。

① 用思考轨迹匹配功能决策

以思考文本作为决策状态的语义代理，用冻结编码器计算学生轮次 u 与其他同任务轨迹教师轮次 v 的相似度。每批 on-policy 数据重新计算对应关系。

保留相似度超过阈值的候选，每条 sibling rollout 最多选一个，再取 top-K。还要求动作可解析且动作嵌入余弦 ≥ 0.8；WebShop 额外匹配操作类型和点击目标。

$$\begin{aligned} \mathbf{d}_u &= \mathrm{Enc}(z_u), \quad \mathbf{d}_v^{+} = \mathrm{Enc}(z_v^{+}) \\ H_{v,u}^{(n)} &= \cos(\mathbf{d}_v^{+,(n)}, \mathbf{d}_u^{(n)}) \\ \mathcal{M}^{(n)} &= \Psi(H^{(n)}; \gamma_H, K) \end{aligned}$$

M 的非零列为匹配权重并归一化；找不到候选时该列为零。

② 对同一个学生响应重新评分

教师在匹配到的历史中 teacher-force 完整学生响应，而不是要求学生模仿检索到的教师答案。因此不同语境评价的是同一串 token。

$$\begin{aligned} \ell_{v\to u,r}^{+} &= \log \pi_\theta^{+}(y_{u,r} \mid h_v, y_{u,<r}) \\ \ell_{u,r} &= \log \pi_\theta(y_{u,r} \mid h_u, y_{u,<r}) \\ \ell_{u,r}^{+,\text{align}} &= \log \sum_v \mathcal{M}_{v,u}^{(n)} \exp(\ell_{v\to u,r}^{+}) \end{aligned}$$

将各匹配语境的教师概率加权混合，得到跨语境证据。u 表示目标轮次，r 表示响应内 token。

③ 按匹配置信度修正局部差值

相似度越可靠，跨语境证据权重越高。没有有效匹配时 α 为零，自动退回原来的局部教师—学生差值。

$$\begin{aligned} \tilde{\delta}_{u,r} = (1-\alpha_u)\ell_{u\to u,r}^{+} \\ + \alpha_u \ell_{u,r}^{+,\text{align}} - \ell_{u,r} \end{aligned}$$

修正的是监督证据，仍然评价当前学生响应。

$$\begin{aligned} \widehat{H}_{v,u} &= \mathrm{clip}\left(\frac{H_{v,u} - \gamma_H}{1-\gamma_H}, 0, 1\right) \\ \rho_u &= \sum_v \mathcal{M}_{v,u}^{(n)} \widehat{H}_{v,u} \\ \alpha_u &= \alpha_{\max} \rho_u \end{aligned}$$

α_max 限制最大修正强度；ρ_u 为匹配的加权置信度。

④ 用对应分布变化划分决策跨度

同一决策连续进行时，相邻轮次通常保留相近的参考语境。先归一化 top-K 截断之前的对应分数，再用相邻分布的 JSD 衡量变化。

批次自适应阈值与时长约束产生连续、可变长度的跨度。一个跨度可覆盖多轮，因此采用 semi-Markov 抽象。

$$\begin{aligned} \mathbf{P}_{i,k}^{(n)} &= \mathrm{Norm}(H_{\cdot,(i,k)}^{(n)}) \\ D_{i,k}^{\text{corr}} &= \mathrm{JSD}(\mathbf{P}_{i,k-1}^{(n)}, \mathbf{P}_{i,k}^{(n)}) \end{aligned}$$

D_corr 的显著变化提供边界依据；跨度长度由对应关系决定。

⑤ 跨度之间、跨度内部两层分配

先对每轮 token 的修正差值求均值，再按轨迹优势的符号定向。跨度证据是内部各轮证据的平均值，决定该跨度得到的信用预算。

跨度预算再按轮次证据分配。KL 约束防止两层分配过度偏离中性分配；有界归一化保持按 token 加权的平均优势。

$$\mathcal{E}_{i,k} = \mathrm{sgn}(A_i^{\text{seq}}) \frac{1}{N_{i,k}} \sum_{r=1}^{N_{i,k}} \tilde{\delta}_{i,k,r}$$

N_i,k 为该轮参与优化的 token 数；证据越大，与整条轨迹结果方向越一致。

$$\mathbf{W}_i = \Phi(\mathcal{S}_i, \mathbf{E}_i; \Lambda_i), \qquad \widehat{A}_{i,k} = A_i^{\text{seq}}\, \mathrm{sg}(W_{i,k})$$

Φ 先分配跨度预算，再分配内部轮次权重。sg 表示停止梯度。

方法 • 实验

⑥ 接入原有策略优化

每个 token 继承所属轮次的加权优势，进入原有 clipped policy loss。基础正则项保持不变，也不另加蒸馏损失。

匹配、分段、证据和分配量全部停止梯度，仅用于训练。部署时仍使用普通策略及其正常交互历史。

实验

三类环境、两种模型规模，共八个汇总指标比较。AlignOPSD 均优于 GRPO 与 StepOPSD，但并非所有设置中的最优方法。

评测设置与比较口径

模型为 Qwen2.5-3B/7B-Instruct。ALFWorld 测成功率，Search-QA 测精确匹配准确率，WebShop 同时测归一化 Score 与完全成功 Acc。

对比无训练提示、RLVR 和自蒸馏 RL 三类方法。带技能的方法共享 SkillBank 与检索源；表中 * 表示评估时仍使用技能，其余技能只用于训练。

表 1 • 完整主结果

Method	ALFWorld							Search-QA								WebShop	
	Pick	Heat	Look	Clean	Cool	Pick2	Avg	NQ	Triv	Pop	Hotp	2Wk	MuS	Bam	Avg	Score	Acc
Qwen2.5-3B-Instruct																	
Vanilla	44.4	15.4	11.1	6.2	28.6	12.5	21.9	24.6	48.1	31.0	26.3	25.3	7.2	59.7	31.7	6.7	0.8
Skill-Prompt*	51.7	0.0	66.7	48.4	4.3	10.0	28.9	23.7	46.2	30.6	24.4	22.1	7.5	12.5	23.9	1.2	0.8
OPSD	48.8	0.0	41.7	16.7	15.8	16.7	28.1	0.1	0.1	0.1	0.0	0.0	0.0	0.0	0.0	11.3	3.1
GRPO	91.2	61.9	62.5	96.2	65.0	47.4	75.0	39.3	60.6	41.1	37.4	34.6	15.4	26.4	36.4	79.8	63.3
Skill-GRPO	88.9	70.6	71.4	58.8	40.7	29.2	60.2	43.5	58.8	43.0	36.8	32.2	11.7	12.5	34.1	77.3	60.9
Skill-GRPO*	94.3	66.7	57.1	**100**	73.1	57.1	80.5	44.3	59.6	44.3	39.0	36.1	14.5	14.9	36.1	76.3	66.4
GRPO+OPSD	**100**	75.0	**82.4**	85.7	70.0	60.0	**81.2**	44.3	60.8	46.0	38.9	38.6	13.9	64.5	43.9	77.8	66.4
Skill-SD	88.2	52.4	50.0	96.2	65.0	57.9	73.4	42.8	60.1	42.2	**39.5**	38.9	13.6	64.9	44.0	75.9	64.0
RLSD	87.9	75.0	75.0	90.9	73.1	68.4	79.7	42.3	58.6	43.3	**39.5**	**39.6**	**16.1**	**66.1**	44.2	84.4	66.4
SDAR	94.6	50.0	66.7	68.2	60.0	**80.0**	74.2	**44.8**	58.1	44.3	38.6	36.2	15.7	**66.1**	43.4	70.7	57.8
StepOPSD	82.4	52.2	66.7	82.6	73.7	75.0	73.4	43.6	**61.2**	43.8	39.2	38.1	15.8	64.5	43.7	82.4	66.4
ALIGNOPSD	88.6	**81.8**	54.5	90.3	**82.6**	58.8	80.5	44.5	**61.2**	**46.3**	**39.5**	38.9	13.7	65.3	**45.1**	**86.8**	**68.8**
Qwen2.5-7B-Instruct																	
Vanilla	36.1	0.0	22.2	3.1	0.0	0.0	12.5	25.2	50.8	29.5	29.0	29.0	10.4	63.7	33.9	5.9	1.6
Skill-Prompt*	51.7	5.3	50.0	32.3	4.3	0.0	23.4	30.9	52.1	32.7	32.7	27.9	12.7	66.1	36.4	1.7	0.8
OPSD	50.0	21.4	60.0	22.7	17.6	9.5	32.8	8.8	8.6	17.5	2.5	4.2	0.5	1.2	6.2	4.5	2.3
GRPO	91.2	81.0	87.5	96.2	65.0	57.9	81.2	45.1	63.7	44.0	43.6	43.2	16.8	37.6	42.0	80.9	72.6
Skill-GRPO	88.5	61.1	66.7	65.2	57.7	73.1	69.5	45.2	63.7	45.7	43.1	43.3	19.6	21.4	40.3	80.4	71.9
Skill-GRPO*	**100**	83.3	83.3	96.4	75.0	**78.9**	88.4	44.8	63.0	45.1	43.7	43.7	20.5	71.4	47.5	87.0	**81.2**
GRPO+OPSD	91.4	87.5	61.5	**100**	76.5	52.2	80.4	**47.3**	64.5	46.9	43.8	39.3	18.0	69.4	47.0	86.8	76.5
Skill-SD	93.9	**100**	**93.8**	90.9	69.2	68.4	85.1	47.1	64.5	47.8	44.2	42.1	20.2	69.0	47.8	86.1	76.5
RLSD	**100**	58.8	87.5	92.3	**80.0**	65.2	82.0	46.8	63.0	44.4	**45.5**	**48.9**	**21.5**	**73.0**	49.0	87.4	77.3
SDAR	94.7	86.7	75.0	**100**	68.2	**78.9**	85.9	46.3	63.5	48.2	43.8	48.4	19.6	**73.0**	49.0	83.6	74.2
StepOPSD	98.1	90.5	75.0	**100**	**80.0**	63.2	88.4	45.3	64.6	45.1	44.5	44.4	19.3	69.8	48.2	87.2	78.1
ALIGNOPSD	70.8	**100**	81.8	**100**	76.5	70.8	**89.1**	46.4	**65.6**	**48.5**	44.6	43.7	19.5	69.8	**49.1**	**87.9**	78.9

表 1：所有方法、模型规模及子任务结果。* 表示评估时使用技能。

3B/7B 的 ALFWorld 均值为 80.5/89.1，Search-QA 为 45.1/49.1，WebShop Score 为 86.8/87.9、Acc 为 68.8/78.9。

八个汇总比较中六项第一、两项第二：3B ALFWorld 低于 GRPO+OPSD 的 81.2；7B WebShop Acc 低于 Skill-GRPO* 的 81.2。

相对 GRPO 的增益是多少

3B/7B 相对 GRPO：ALFWorld 增加 5.5/7.9 个百分点，Search-QA 增加 8.7/7.1 个百分点；WebShop Score 均增加 7.0 个百分点，Acc 增加 5.5/6.3 个百分点。

共享特权信息源仍出现差异，说明收益不只来自额外信息，还与证据对齐和结果条件化信用分配有关。

表 2 • 对齐和自适应跨度都有效

#	Variant	Score	Acc
–	**ALIGNOPSD**	**87.9**	**78.9**
1	w/o rectification + adaptive allocation	84.2	71.9
2	w/ rectification + token allocation	81.6	71.1
3	w/ rectification + turn allocation	86.3	77.3
4	w/ rectification + random allocation	78.9	69.5

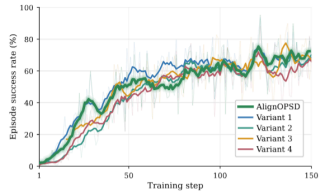


表 2：四种消融的终点结果与训练曲线。

WebShop 7B 完整方法 Score/Acc 为 87.9/78.9。去掉监督修正后降至 84.2/71.9，说明只保留自适应分配还不够。

保留修正但改用 token、turn、随机分配，分别为 81.6/71.1、86.3/77.3、78.9/69.5。逐轮比逐 token 更好，而可变决策跨度进一步提升。

实验 • 局限 • 未来展望

图 3 • 超参数效果依任务而变

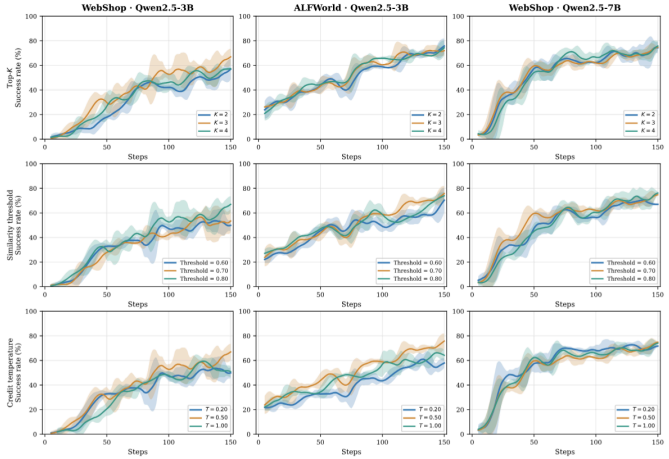


图 3：top-K、相似度阈值和信用温度的敏感性。

top-K 的最佳值并不统一：ALFWorld 3B 偏好 K=2，WebShop 3B 偏好 K=3，WebShop 7B 偏好 K=4。更多参考证据可能混入不相关匹配。

相似度阈值 0.70–0.80 在测试中较有效，WebShop 对筛选更敏感。信用温度 T=0.5 在三个设置中均较好；3B 对温度变化更敏感。

图中曲线平滑了验证检查点，阴影是局部时间变化的两倍，不是跨随机种子的置信区间。

图 4(a–b) • 对应关系决定分段

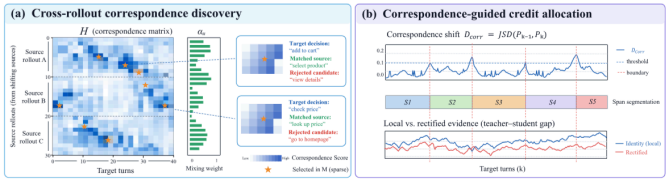


图 4(a–b)：对应匹配、置信度与分段。

高相似度匹配可以跨越不同时间位置；对应分布的突变给出决策边界。局部证据与修正后证据的曲线不同，说明匹配改变了后续信用分配的输入。

图 4(c–d) • 决策粒度随任务变化

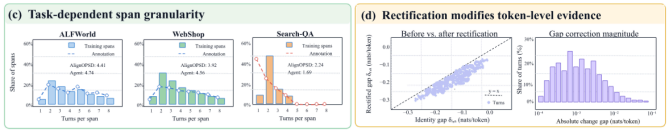


图 4(c–d)：跨度分布与修正前后证据。

平均跨度：ALFWorld 4.41 轮、WebShop 3.92 轮、Search-QA 2.24 轮。检索问答更集中于短跨度，支持按任务中的决策变化自适应分段。

修正前后 gap 的散点偏离恒等线，修改幅度覆盖许多轮次；结合消融，说明跨语境评分确实改变了监督，而非原差值的重复使用。

局限

证据主要覆盖两种 Qwen2.5 规模与三类环境；功能对应依赖语义代理和动作过滤，超参数也存在任务差异。

功能匹配是近似，结论有范围

思考文本被用作决策状态的语义代理，嵌入相近被视为近似功能对应。动作过滤降低错配风险，无法匹配时回退局部证据。

top-K 与相似度阈值的最佳选择会随任务、模型规模变化。敏感性曲线描述测试区间内的经验表现，不能据此推断跨种子稳定性。

未来展望

正文未提出具体后续研究计划；其结论强调可推广的训练原则：先让监督对应实际功能决策，再把它用于有结果依据的信用分配。

从时间位置转向决策语义

这一原则同时约束监督语境与时间粒度：跨轨迹寻找可比较的证据，轨迹内部采用适应决策持续时间的信用单元。