HarnessForge: Joint Harness and Policy Evolution for Adaptive Agent Systems

让执行框架与推理策略成对演化

Mingju Chen et al. · arXiv:2606.01779v1 · 2026

背景

核心问题：外部框架变好了，模型是否能可靠执行它？ HarnessForge 将执行框架与模型策略视为一个耦合系统，以成对演化改善工具使用和多跳问答。

复杂任务需要不同的执行方式

工具调用依赖严格的参数与接口，多跳检索需要分解问题，持续交互还需要状态追踪与记忆。任务之间的差别不仅是难度，也包括如何组织执行。

固定的人工框架难以适配所有任务。对较小模型而言，框架能补充结构支持，但模型也必须学会遵守它暴露的计划、动作和记忆接口。

兼容性缺口：组件强，不等于组合强

更复杂的 harness 可能提供有用信息，却因模型执行不稳定而失效；更强的策略也可能受制于不合适的状态、动作与控制信号。优化对象应是二者的组合。

本文交替进行失败引导的框架修改与框架条件下的策略训练，再选择匹配的组合进入下一轮。

相关工作

已有研究分别搜索外部执行结构，或训练内部推理策略；本文把两者的可执行兼容性显式纳入优化。

外部结构：从人工工作流到自动搜索

CoT、Plan-and-Solve、ReAct 定义推理与交互模式；AutoGen、MetaGPT、记忆增强系统增加角色、协议和记忆模块。

ADAS、AFlow、AgentSquare、MaAS 等搜索框架或工作流，主要改外部结构，通常没有联合训练与之配套的模型执行器。

内部策略：在给定接口内学会行动

Search-R1、ToolRL、ToRL 学习何时及如何调用外部工具；GiGPO、TreeRL、ARPO 处理长期交互与信用分配。这条路线一般假设交互循环或接口预先固定。

图 1 · 三种适应方式的区别

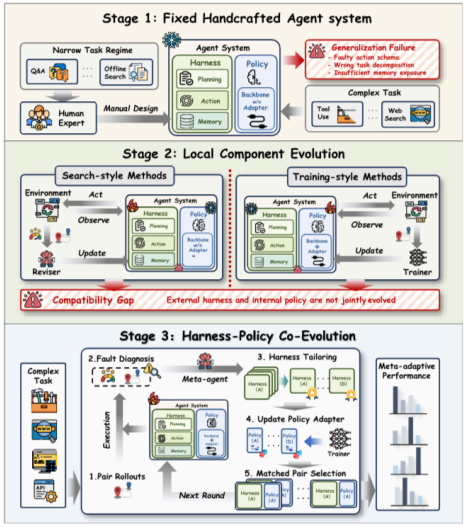


Figure 1: A three-stage view of LLM agent adaptation: fixed handcrafted systems, local component adaptation, and harness–policy co-evolution (HarnessForge).

图 1：固定系统、组件演化与框架—策略共同演化。

从固定人工系统，到仅修改一个组件，再到同时演化 harness 与 policy。关键变化是把“匹配的一对”作为下一轮的继承单元。

方法

方法

每轮先改框架，再对齐策略。 轨迹反馈用于定位故障、搜索候选框架，也被复用于训练轻量适配器，减少额外采样。

图 2a · 系统由哪些部分组成?

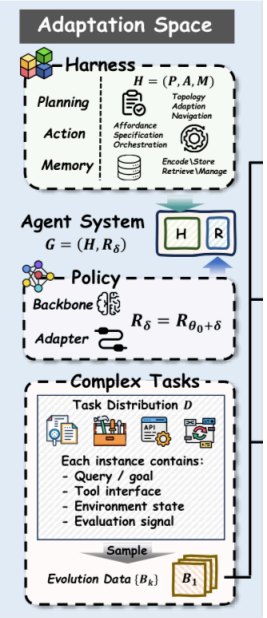


图 2 左：计划、动作、记忆与适配器组成可演化系统。

$\mathcal{H}$ 包含计划、动作和记忆；$\mathcal{R}_\delta$ 是基础推理模型加轻量适配器。计划负责分解与终止，动作负责工具协议，记忆负责写入、检索及暴露信息。

$$\mathcal{G} = (\mathcal{H}, \mathcal{R}_\delta),$$
$$\mathcal{H} = (\mathcal{P}, \mathcal{A}, \mathcal{M}), \qquad \mathcal{R}_\delta = \mathcal{R}_{\theta_0+\delta}$$

θ_0 为基础模型参数，δ 为适配器；优化的是可执行的系统组合。

图 2b · 多轮演化与匹配继承

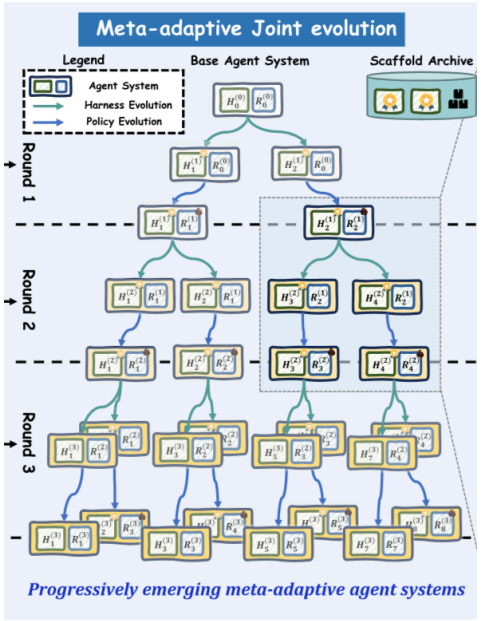


图 2 中：交替修改框架与策略，形成多条系统谱系。

初始种群只有人工框架与冻结基础模型。每轮在任务批次上收集轨迹，筛选修改后的框架，为幸存框架训练专属策略，再把匹配组合交给下一轮。

策略训练的目标是适应所选框架的执行约定，不是声称获得一个对所有任务普遍更强的模型。

图 2c · 定位故障，再修改框架

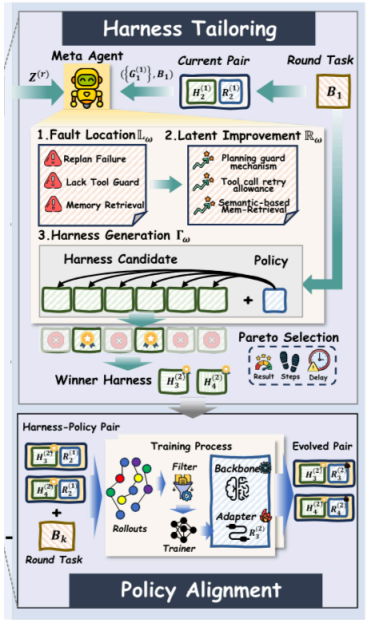


图 2 右：故障定位、候选生成、Pareto 筛选与策略对齐。

元智能体联合查看框架代码、代表性失败轨迹和评价向量，把错误归因到计划、动作或记忆。随后检索与故障相关且质量较好的历史框架，形成修改报告并生成候选。

候选只编辑执行层组件。先用较小任务子集评估，逐步扩大评估范围并筛选，以降低完整评估全部候选的成本。

选择标准：质量、开销与延迟

评价向量汇总最终回答质量、负 token 成本与负延迟，各维都以更大为好。Pareto 选择保留不同权衡下的候选，已评估框架及得分进入历史档案。

$$\mathbf{J}(\mathcal{G}; B) = \frac{1}{|B|} \sum_{x \in B} \phi(\tau_x(\mathcal{G}), x)$$

B 为任务批次，τ_x 为系统执行轨迹，φ 返回多维评价结果。

方法 • 实验

策略对齐：复用成功轨迹训练 LoRA

子策略从父系继承参数，再训练新的框架专属 LoRA 更新。筛选过程中已产生的轨迹不丢弃，只保留成功轨迹用于主要实验中的监督对齐。

每一步输入含任务、当前框架接口、累计观察、记忆和可用动作；目标是下一步推理、工具调用、记忆操作或最终回答。

$$\mathcal{T}_k^{+} = \{\tau_x \in \mathcal{T}_k^{(r+1)} \mid S(\tau_x) = 1\}$$

S 表示任务成功；训练数据由保留轨迹中的逐步决策对组成。

$$\Delta\delta_k^{(r+1)} = \arg\min_{\Delta\delta} \mathcal{L}\left(\mathcal{R}_{\delta_k}^{(r)} \oplus \Delta\delta; \mathcal{D}_{\mathcal{H}_k}\right)$$

只学习继承策略之上的增量适配器；该训练阶段复用已有 rollout。

实验

正文通过主结果、模块消融、预算曲线、交叉配对与演化案例，检验联合演化是否优于仅改框架或仅训练策略。

任务、模型与比较对象

工具任务为 ToolHop、RestBench-TMDB、API-Bank；SearchQA 包含 HotpotQA 与 2WikiMultiHopQA。后两项按一个检索问答组汇报，不能把指标列数当作独立任务数。

基础模型为 Qwen3-4B、8B，元智能体为 GPT-5.5；主设置演化 3 轮，每轮保留 2 个框架。比较搜索式方法与 SFT、GRPO、RLOO。

表 1 • 两种规模下的主结果

Table 1: Main results across benchmark groups for the Qwen3-4B and Qwen3-8B backbones. pale blue rows indicate search-style methods, soft blue rows indicate training-style methods, and blue-purple rows indicate our HarnessForge framework. Detailed benchmark and baseline configurations are provided in App. B and App. E.

Method	ToolHop		SearchQA			TMDB		API-Bank		
	Ans.	Path	Hotpot	2Wiki	Overall	Succ.	Path	Succ.	Path	API.
Qwen3-4B										
ADAS	40.00	44.99	28.67	28.00	28.33	45.00	57.43	51.75	57.31	60.99
AgentSquare	29.23	39.46	29.33	30.00	29.67	35.00	49.83	39.47	47.82	46.10
AFlow	31.28	43.81	30.67	29.33	30.00	32.00	47.64	37.72	45.72	41.13
MaAS	42.05	51.80	30.67	30.00	30.33	37.00	46.57	52.63	62.74	63.83
MermaidFlow	44.62	58.74	31.33	28.00	29.67	39.00	51.95	54.39	64.33	60.28
SFT	45.13	63.90	36.67	38.67	37.67	61.00	75.70	69.30	75.10	73.76
RLOO	46.15	64.87	35.33	40.00	37.67	61.00	77.42	72.81	78.82	76.60
GRPO	49.74	66.41	36.00	**43.33**	39.67	64.00	76.67	71.93	76.46	75.18
HarnessForge	**52.82**	**68.10**	**42.00**	42.00	**42.00**	**76.00**	**85.10**	**77.19**	**80.07**	**82.27**
Qwen3-8B										
ADAS	42.05	61.32	31.33	32.00	31.67	51.00	60.41	54.39	60.14	59.57
AgentSquare	30.77	41.22	29.33	30.00	29.50	38.00	53.83	45.61	54.37	53.90
AFlow	32.82	54.12	31.33	32.67	32.00	39.00	51.28	43.86	49.74	47.52
MaAS	44.62	51.80	32.00	32.00	32.00	43.00	54.78	57.89	66.72	60.28
MermaidFlow	47.39	59.31	32.67	30.67	31.67	47.00	58.67	57.02	67.46	62.41
SFT	48.72	72.20	40.67	41.33	41.00	69.00	82.92	68.42	73.80	73.05
RLOO	50.77	72.75	40.00	39.33	39.67	74.00	84.25	66.67	73.76	71.63
GRPO	51.28	**75.62**	41.33	42.00	41.67	70.00	83.20	69.30	74.71	73.76
HarnessForge	**54.87**	74.05	**41.33**	**44.33**	**42.83**	**80.00**	**88.75**	**74.56**	**78.22**	**78.01**

表 1：4B 与 8B 全部主结果。Ans. 为答案指标，Path 为路径指标；不同任务的指标定义各异。

4B 在 TMDB 成功率达到 **76.00%**，最强基线为 64.00%，增加 **12 个百分点**；8B 为 80.00%，相对最强基线 74.00% 增加 6 个百分点。

优势不是每一列都成立：4B 的 2Wiki 为 42.00，低于 GRPO 的 43.33；8B 的 ToolHop Path 为 74.05，低于 GRPO 的 75.62。

表 2 • 两个演化环节都有效

Table 2: Module ablation of HarnessForge using Qwen3-4B. ToolHop reports final-answer correctness, and SearchQA reports the macro-average answer F1.

Round	Variant	ToolHop	SearchQA
Round0	Vanilla	41.03	34.33
Round1	HarnessForge	46.15	38.67
	-w/o Harness Evo.	43.08 (↓3.07)	35.67 (↓3.00)
	-w/o Policy Evo.	44.62 (↓1.53)	36.33 (↓2.34)
Round2	HarnessForge	50.77	40.33
	-w/o Harness Evo.	44.62 (↓6.15)	36.33 (↓4.00)
	-w/o Policy Evo.	48.72 (↓2.05)	38.33 (↓2.00)
Round3	HarnessForge	52.82	42.00
	-w/o Harness Evo.	46.67 (↓6.15)	37.00 (↓5.00)
	-w/o Policy Evo.	50.26 (↓2.56)	39.00 (↓3.00)

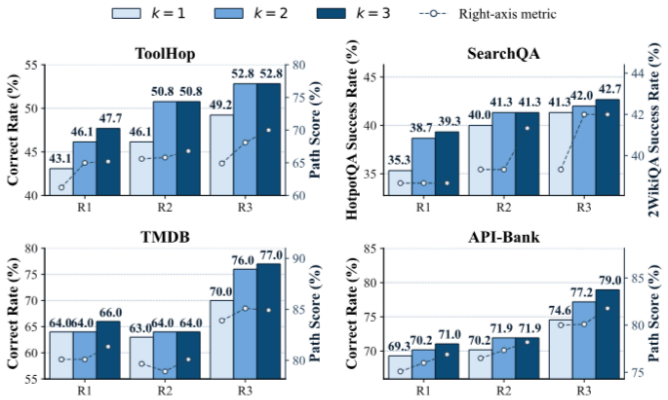
表 2：Qwen3-4B；ToolHop 正确率与 SearchQA 宏平均答案 F1。

4B 第 3 轮完整方法在 ToolHop / SearchQA 为 **52.82 / 42.00**。去掉框架演化降至 46.67 / 37.00；去掉策略演化降至 50.26 / 39.00。

框架修改贡献较大，配套策略训练仍有额外价值；随着轮数增加，缺少其中任一环节的差距整体扩大。

实验

图 3a • 保留多少候选?

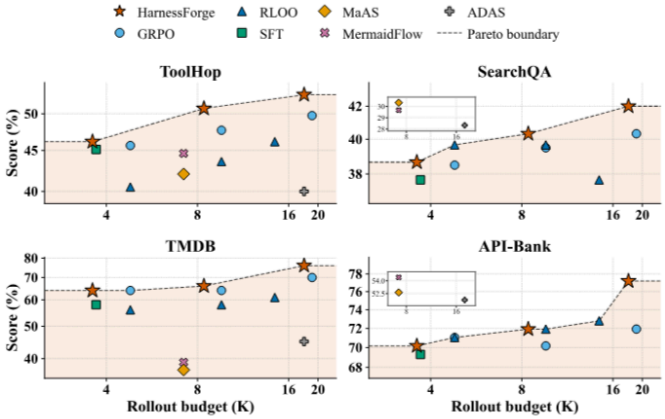


(a) Retained-harness sensitivity across four benchmark groups.

图 3a：候选数 k=1、2、3；R1–R3 为演化轮次，虚线对应右轴指标。

保留一个框架容易过早收窄搜索；从 1 个增至 2 个，最后一轮四组主指标平均增加约 3.2 个百分点。继续增至 3 个多数收益较小，主设置取 2。

图 3b • 结果与 rollout 预算



(b) Budget–performance Pareto analysis across benchmarks.

图 3b：rollout 预算与性能；星号为 HarnessForge。

在所比较预算下，HarnessForge 位于或接近经验 Pareto 前沿。它把同一批轨迹用于框架诊断与策略对齐，以更充分地利用采样。

这里衡量的是 rollout 数量与结果的权衡，不能直接替代包含元模型调用、训练时间在内的全部计算成本比较。

图 4 • 为什么必须成对适配?

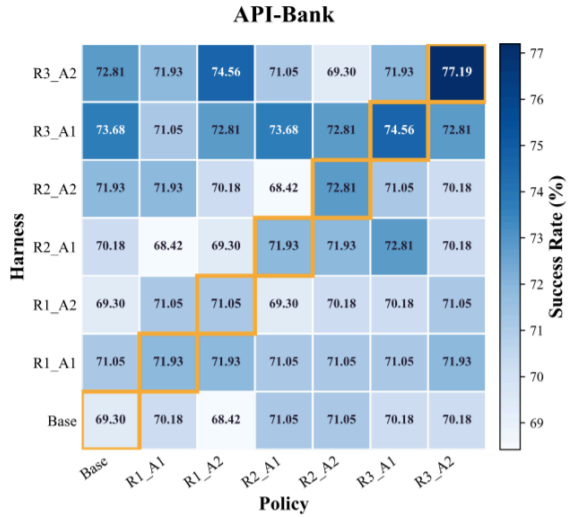


Figure 4: Harness–policy compatibility matrices on API-Bank. Rows denote evolved harnesses and columns denote evolved policy across evolution rounds.

图 4：API-Bank；行是框架，列是策略，黄色边框为匹配组合。

API-Bank 的匹配组合从 **69.30%** 升至 **77.19%**。最终框架搭配旧策略平均只有 71.93%；最终策略搭配旧框架平均为 71.06%。

交叉配对的退化支持“组合专属的兼容性收益”，不宜把进步全部归因于独立组件变强。

实验 • 局限 • 未来展望

表 3 • 更换策略训练方法的代价

Table 3: Training agnostic analysis. We evaluate HarnessForge+SFT, HarnessForge+GRPO, and HarnessForge+RLOO on ToolHop, and report API-Bank as an auxiliary transfer/evaluation setting.

Round	Training	ToolHop		API-Bank			Budget (K)
		Ans.	Path	Succ.	Path	API.	
1	SFT	45.13	60.66	69.30	74.85	73.05	2.40
	GRPO	45.64	59.49	70.18	**76.02**	**74.47**	7.20
	RLOO	**46.67**	**61.17**	**70.18**	75.73	73.76	7.20
2	SFT	48.72	63.70	71.05	75.15	**75.89**	5.60
	GRPO	49.23	**64.28**	69.30	76.90	73.76	20.00
	RLOO	**49.74**	63.80	**71.05**	**77.78**	75.18	20.00
3	SFT	50.77	65.87	71.05	76.90	75.18	12.00
	GRPO	**52.31**	**67.32**	71.93	77.78	75.18	45.60
	RLOO	51.28	66.45	**72.80**	**79.09**	**76.60**	45.60

表 3：训练方式比较，Budget 的单位为千次 rollout。

同一框架可使用 SFT、GRPO 或 RLOO。第 3 轮 ToolHop 答案正确率从 SFT 的 50.77% 增至 GRPO 的 52.31%，但 rollout 从 **12.0K** 增至 **45.6K**。

表 3 是训练方式分析设置，数值不等同于表 1 的主设置。更高性能伴随更高采样开销，SFT 因复用成功轨迹而成为默认实现。

图 5 • 一条系统谱系如何逐轮变好?

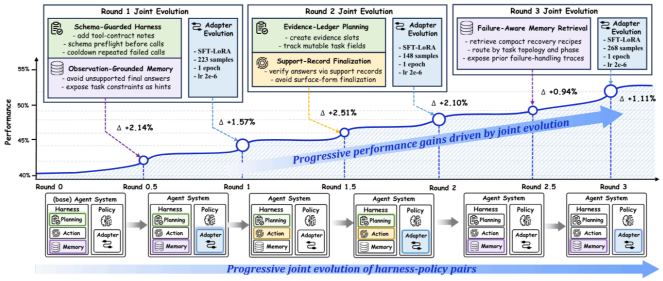


Figure 5: Representative ToolHop lineage of HarnessForge across three harness–policy co-evolution rounds.

图 5：ToolHop 示例谱系，框架修订与适配器训练交替发生。

示例先增加工具 schema 检查与可靠的记忆暴露，再引入证据记录和答案支持检查，最后改进失败相关记忆检索。每次框架调整之后都进行适配器更新。

图中一次次增益展示交替演化过程；它是一条代表性谱系，不代表所有任务、每条候选分支都会单调提升。

局限

结果主要来自中小规模 Qwen 模型和受约束的编辑空间；长程执行成本与更大模型上的收益仍是边界。

规模与任务覆盖

实验主要使用 Qwen3-4B、8B。框架为有限模型能力提供的结构支持，是否同样有利于更大前沿模型，尚未验证。

重复评估仍然昂贵

轨迹虽然被复用，但框架诊断、筛选与对齐仍需多轮执行；长时程环境会使整个演化流程昂贵。

编辑空间与方法边界

当前只在计划、动作、记忆组件内受约束地修改，利于可执行性与审计，却没有遍历任意代码级重写、新工具抽象或学习型验证器。

未来展望

作者提出扩大模型与编辑空间，并用更节省成本的评估和元智能体提高演化效率。

作者明确提出的方向

用代理评估、自适应 rollout 分配或学习型提前停止降低搜索成本。

扩展可编辑算子，研究不同闭源 / 开源元智能体下的成本感知演化，并检验更大模型上的配对收益。