Attention Is All You Need

Vaswani et al. · NeurIPS 2017 · arXiv:1706.03762v7

Transformer：用注意力连接序列中的每个位置

背景

核心问题：如何同时提高训练并行性与远距离信息交互能力？ Transformer 用注意力构建编码器和解码器，在机器翻译中验证效果。

任务设定：从输入序列生成输出序列

机器翻译属于**序列转换**：输入是源语言符号序列，输出是目标语言符号序列。编码器先构造输入表示，解码器再据此逐步生成输出。

此前的主流模型沿词的位置依次计算隐藏状态。论文关注的不仅是翻译质量，也包括这种计算方式带来的训练效率约束。

瓶颈：序列计算必须逐步等待

RNN 的顺序依赖。 后一个隐藏状态依赖前一个状态，单个样本内难以并行；长序列还会限制批处理规模。

新的切入点。 注意力已经能关联远处信息，但当时多数模型仍将它附加在 RNN 上。本文让注意力直接承担序列表示构建。

贡献：重组整个序列转换架构

保留编码器—解码器框架，组合**多头注意力、逐位置前馈网络、位置编码**，去掉序列对齐的循环与卷积。

大模型的英德 / 英法翻译达到 **28.4 / 41.8 BLEU**（摘要与表 2）；英语成分句法分析提供了任务迁移证据。

相关工作

创新在于架构组合。 自注意力此前已用于多种任务；本文将其作为序列表示的主要机制，并改变了信息交互路径。

三条路线，三种信息传递方式

循环 | RNN / LSTM / GRU。 广泛用于语言建模和机器翻译。编码器表示输入，解码器逐步输出；跨序列注意力使解码器能按需读取源位置，但循环计算的顺序约束仍在。

卷积 | ByteNet / ConvS2S。 可并行计算各位置表示；远距离词之间的信息传递需要跨越多层，路径随位置距离增长，增加了学习长距离依赖的难度。

自注意力 | 已有基础。 直接关联同一序列中的不同位置，已用于阅读理解、摘要、文本蕴含和句子表示；记忆网络也采用注意力机制。

本文的区别：改变信息交互路径

自注意力让任意两个位置在一层内建立联系；加权平均可能降低有效分辨率，论文用**多头机制**缓解这一问题。

作者强调的创新是：完全依赖自注意力构造输入、输出表示的序列转换架构，不再使用序列对齐的循环或卷积。

方法

先跨位置交换信息，再在位置内做非线性变换。 编码器整合源句，解码器结合目标前缀与源句表示预测下一个词。

图 1 • 编码器—解码器

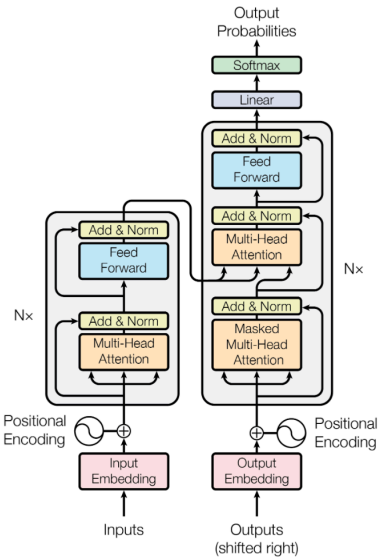


Figure 1: The Transformer - model architecture.

左：编码器；右：解码器。N× 表示重复堆叠。

base 配置： 编码器、解码器各 6 层，$d_{\text{model}} = 512$。编码器每层包含注意力与 FFN；解码器额外读取编码器输出。

信息流： 左侧编码源句 → 右侧读取目标前缀 → 顶部预测下一个词。右移输入与掩码共同防止训练时泄露未来答案。

方法

三种注意力：Q、K、V 从哪里来?

编码器自注意力： Q、K、V 来自同一源序列表示，可读取全部源位置。

解码器自注意力： 读取目标前缀；未来位置的分数在 softmax 前设为 $-\infty$。

跨注意力： Q 来自解码器，K、V 来自编码器输出，使目标位置按需读取整个源句。

缩放点积：匹配 → 分配权重 → 读取

Q 是查询，K 用于匹配，V 承载内容。先计算查询与键的相似度，再对每个查询沿键维归一化，最后对 V 加权求和。

为什么缩放？ 键维度较大时，点积可能使 softmax 饱和、梯度变小；除以 $\sqrt{d_k}$ 可校正分数尺度。

$$\text{Attention}(Q,K,V)=\text{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}\right)V$$

$Q\in\mathbb{R}^{n_q\times d_k}$，$K\in\mathbb{R}^{n_k\times d_k}$，$V\in\mathbb{R}^{n_k\times d_v}$；输出为 $n_q\times d_v$。

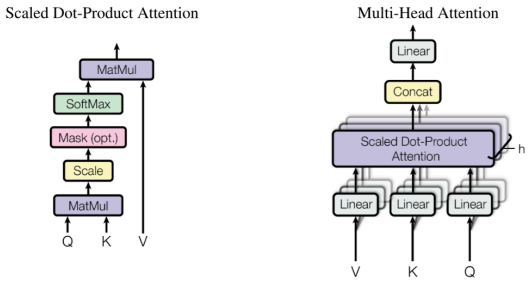


Figure 2: (left) Scaled Dot-Product Attention. (right) Multi-Head Attention consists of several attention layers running in parallel.

左：缩放点积；右：多头的投影、并行计算与拼接。

多头：在不同子空间并行读取

每个头独立学习 Q、K、V 的线性投影；各头结果拼接后，经 W^O 投回模型维度。

base 使用 $h=8$，$d_k=d_v=64$。各头维度较小，使总计算量与全维度单头相近。

$$\begin{aligned}&\text{head}_i\\&=\text{Attention}(QW_i^Q,KW_i^K,VW_i^V)\\&\text{MultiHead}(Q,K,V)\\&=\text{Concat}(\text{head}_1,\dots,\text{head}_h)W^O\end{aligned}$$

W_i^Q,W_i^K,W_i^V 为各头投影；W^O 为输出投影。

FFN 与残差：位置内变换、逐层堆叠

FFN 在每个位置独立应用两层线性变换和 ReLU。同层跨位置共享参数，不同层参数不同；base 的 $d_{\text{ff}}=2048$。

原版采用 **Post-LN**：先做残差相加，再做层归一化。

$$\text{FFN}(x)=\max(0,xW_1+b_1)W_2+b_2$$

x 为单个位置的表示；先扩维，再投回 d_{model}。

$$\text{LayerNorm}(x+\text{Sublayer}(x))$$

Sublayer 为注意力或 FFN；残差两端维度一致。

位置编码：把词序加入表示

词嵌入与同维度的位置编码相加；本文采用不同频率的正弦、余弦。

作者假设这种编码便于学习相对位置，并可能外推到更长序列。实验只显示它与学习式编码效果接近。

输入 / 输出嵌入与 softmax 前线性层共享权重；嵌入权重乘以 $\sqrt{d_{\text{model}}}$。

$$\begin{aligned}\text{PE}_{(pos,2i)}&=\sin\left(pos/10000^{2i/d_{\text{model}}}\right)\\\text{PE}_{(pos,2i+1)}&=\cos\left(pos/10000^{2i/d_{\text{model}}}\right)\end{aligned}$$

pos 为位置；i 为维度对索引。偶数维用 sin，奇数维用 cos。

表 1 • 并行性与路径长度

Table 1: Maximum path lengths, per-layer complexity and minimum number of sequential operations for different layer types. n is the sequence length, d is the representation dimension, k is the kernel size of convolutions and r the size of the neighborhood in restricted self-attention.

Layer Type	Complexity per Layer	Sequential Operations	Maximum Path Length
Self-Attention	$O(n^2\cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n\cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k\cdot n\cdot d^2)$	$O(1)$	$O(log_k(n))$
Self-Attention (restricted)	$O(r\cdot n\cdot d)$	$O(1)$	$O(n/r)$

n：序列长度；d：表示维度；k：卷积核宽度；r：局部注意力邻域。

自注意力每层计算量为 $O(n^2d)$，顺序操作数与最长路径均为 $O(1)$。表中比较的是**层内计算**，不代表自回归生成无需逐步执行。

当 $n<d$ 时计算优势更明显。长序列的两两交互代价较高；局部注意力可降低开销，但会延长信息路径。

方法 • 实验

关键区分：训练并行，生成仍逐词

训练时目标序列已知，可用因果掩码并行计算各位置；生成时下一个词依赖已有输出，**原版 Transformer 仍是自回归模型**。

实验

翻译、**消融**、**句法分析**分别检验模型效果、组件作用与任务迁移。

训练配置：数据、规模与预算

数据。 英德约 450 万句对、3.7 万共享 BPE 词表；英法 3600 万句、3.2 万 word-piece 词表。每批约含 2.5 万源 token 与 2.5 万目标 token。

预算。 单机 8 张 P100；base 训练 10 万步、约 12 小时，big 训练 30 万步、约 3.5 天。

规模。 base / big：模型维度 512 / 1024，FFN 维度 2048 / 4096，头数 8 / 16；参数量约 6500 万 / 2.13 亿。两者均为 6 层。

训练细节：学习率与正则化

Adam：$\beta_1 = 0.9$、$\beta_2 = 0.98$、$\epsilon = 10^{-9}$。学习率先线性升高，再随步数平方根的倒数衰减。

base 的 dropout 为 0.1，作用于子层输出及嵌入之和；标签平滑为 0.1。

$$\text{lrate} = d_{\text{model}}^{-1/2} \min\left(s^{-1/2},\ s\, w^{-3/2}\right)$$

s 为训练步数，$w = 4000$ 为 warmup 步数。

比较前先核对评估协议

表 2 | newstest2014。 base / big 分别平均最后 5 / 20 个 checkpoint；beam=4，长度惩罚 $\alpha = 0.6$，最大输出为输入长度 +50。

表 3 | newstest2013。 不做 checkpoint 平均。因此消融基准的 25.8 与测试集的 27.3 BLEU 不能直接相减解释。

表 2 • 主要翻译结果

Table 2: The Transformer achieves better BLEU scores than previous state-of-the-art models on the English-to-German and English-to-French newstest2014 tests at a fraction of the training cost.

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [18]	23.75			
Deep-Att + PosUnk [39]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [38]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [9]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [32]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [39]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [38]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [9]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.8**	$2.3 \cdot 10^{19}$	

newstest2014；BLEU 越高越好，训练成本为估计 FLOPs。

big：28.4 / 41.8 BLEU。 英德超过表中已有单模型与集成结果；base 为 27.3 / 38.1，不能把它的英法结果也描述成全面领先。

训练成本约为 base 3.3×10^{18}、big 2.3×10^{19} FLOPs。该值来自估算，并非统一硬件上的耗时对照。

原文差异与任务专属配置

英法 BLEU： 摘要与表 2 报告 41.8，正文 §6.1 写作 41.0，两处数值不一致。

英法 big 的 dropout 为 0.1，而非一般 big 配置的 0.3。

实验 • 局限 • 未来展望

表 3 • 哪些设计起作用?

Table 3: Variations on the Transformer architecture. Unlisted values are identical to those of the base model. All metrics are on the English-to-German translation development set, newstest2013. Listed perplexities are per-wordpiece, according to our byte-pair encoding, and should not be compared to per-word perplexities.

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65
(A)				1	512	512				5.29	24.9	
				4	128	128				5.00	25.5	
				16	32	32				4.91	25.8	
				32	16	16				5.01	25.4	
(B)					16					5.16	25.1	58
					32					5.01	25.4	60
(C)	2									6.11	23.7	36
	4									5.19	25.3	50
	8									4.88	25.5	80
		256			32	32				5.75	24.5	28
		1024			128	128				4.66	26.0	168
			1024							5.12	25.4	53
			4096							4.75	26.2	90
(D)							0.0			5.77	24.6	
							0.2			4.95	25.5	
								0.0		4.67	25.3	
								0.2		5.47	25.7	
(E)	positional embedding instead of sinusoids									4.92	25.7	
big	6	1024	4096	16			0.3		300K	**4.33**	**26.4**	213

英德 newstest2013；不做 checkpoint 平均。参数量单位：百万。

多头有效，但越多未必越好。 单头为 24.9，8 头为 25.8 BLEU；键维度过小会损伤结果。

正则化有帮助。 去掉 dropout 降至 24.6；去掉标签平滑，PPL 改善到 4.67，但 BLEU 从 25.8 降至 25.3。

位置编码选择相近。 学习式为 25.7，正弦式为 25.8 BLEU。PPL 按 word-piece 计算。

表 4 • 迁移到英语成分句法分析

Table 4: The Transformer generalizes well to English constituency parsing (Results are on Section 23 of WSJ)

Parser	Training	WSJ 23 F1
Vinyals & Kaiser el al. (2014) [37]	WSJ only, discriminative	88.3
Petrov et al. (2006) [29]	WSJ only, discriminative	90.4
Zhu et al. (2013) [40]	WSJ only, discriminative	90.4
Dyer et al. (2016) [8]	WSJ only, discriminative	91.7
Transformer (4 layers)	WSJ only, discriminative	91.3
Zhu et al. (2013) [40]	semi-supervised	91.3
Huang & Harper (2009) [14]	semi-supervised	91.3
McClosky et al. (2006) [26]	semi-supervised	92.1
Vinyals & Kaiser el al. (2014) [37]	semi-supervised	92.1
Transformer (4 layers)	semi-supervised	92.7
Luong et al. (2015) [23]	multi-task	93.0
Dyer et al. (2016) [8]	generative	93.3

WSJ Section 23；F1 越高越好。WSJ-only 与半监督条件分别比较。

使用 4 层、$d_{\text{model}} = 1024$ 的模型。WSJ 监督数据约 4 万句；半监督另有约 1700 万句。评估为 WSJ Section 23 的 F1。

Transformer 的 WSJ-only / 半监督结果为 **91.3 / 92.7 F1**。其他训练或建模设置仍有 93.0、93.3；证据支持迁移潜力，不能概括成所有设置下最佳。

该任务用 beam=21、$\alpha = 0.3$，最大输出为输入长度 +300；与翻译配置不同。

局限

自注意力减少了层内顺序操作，但长序列计算与逐词生成仍是约束。

长序列：短路径仍有计算代价

全局自注意力计算量随 n^2 增长。局部化可以降低开销，但最长路径会增至 $O(n/r)$。

结构上的短路径不保证在所有长度、任务和硬件上都更快。

推理：输出仍然有顺序依赖

生成下一个词时仍要读取已有输出。训练并行性的提升不能直接等同于推理延迟的同等改善。

结论：注意任务与比较范围

直接证据覆盖两项翻译任务和英语句法分析；图像、音频、视频属于未来计划。

base 与 big 同时改变规模、预算和正则；结果不能全部归因于某个单独部件。

正弦编码的长序列外推只是可能性，正文未给出系统的超长输入验证。

未来展望

作者提出三条方向：**扩展任务与模态、研究局部注意力、减少生成的顺序性。**

作者明确提出的方向

扩展应用。 将 Transformer 用于更多任务，以及图像、音频、视频等输入输出。

处理大序列。 研究局部、受限注意力，兼顾计算效率与远距离信息传递。

减少串行生成。 正文提出研究目标，但没有给出完成的非自回归方案。