Gaussian Error Linear Units (GELUs)

Dan Hendrycks · Kevin Gimpel · arXiv:1606.08415v5

GELU：按输入大小连续加权的激活函数

背景

研究问题：能否把激活函数与随机门控的思路结合起来？ GELU 从依赖输入的随机掩码出发，取其期望，得到可直接用于神经网络的确定性激活函数。

激活函数为什么重要?

如果没有非线性，堆叠线性层仍只能形成线性映射。激活函数决定神经元如何响应输入，也会影响深层网络的优化与收敛。

早期神经元使用二值阈值，sigmoid 将其平滑化；深层网络中，按输入正负进行硬门控的 ReLU 则成为有效的工程选择。

激活与正则化：两种操作，同一输出

ReLU 用确定性的 0/1 门控改变输出，dropout 用随机置零抑制过拟合。两者通常分别设计，但共同决定神经元的输出。

本文让“是否保留”依赖输入大小，再把随机变换取期望。目标是得到一种既有概率解释、又能跨任务验证的非线性。

相关工作

从符号门控到数值加权。 ReLU、ELU 提供激活函数基线，dropout、zoneout 与 Adaptive Dropout 提供随机门控的动机。

ReLU 与 ELU：基线与区别

ReLU 按符号决定是否通过输入；**ELU** 允许负输出。论文将二者作为主要比较对象，考察训练、泛化与不同任务中的表现。

GELU 用连续权重改变输入，不把所有正输入都原样通过，也不把所有负输入都直接置零。

随机门控如何导向确定性激活?

dropout 随机置零，zoneout 随机保留。本文借用这种 0/1 选择，但令保留概率依赖当前输入。

Adaptive Dropout 同样依赖输入，但采用 logistic 分布，并与激活函数搭配使用。GELU 从标准正态分布出发，将随机变换的期望直接用作激活函数。

方法

先定义输入相关的保留概率，再取输出期望。 标准 GELU 使用标准正态分布的累积分布函数，不额外引入可调参数。

第一步：输入越小，越可能被丢弃

设输入为 x，保留概率为 $\Phi(x)$。作者以神经元输入往往近似正态、尤其使用 Batch Normalization 时为动机；这不是对所有网络输入的保证。

$$m \sim \text{Bernoulli}(\Phi(x)), \qquad y = mx$$

m 为 0/1 随机掩码，Φ 为标准正态累积分布函数。

第二步：取期望，得到 GELU

保留时输出 x，丢弃时输出 0。两种输出按概率加权，得到确定性的 $x\Phi(x)$；使用 GELU 本身不需要在每次前向中采样这个掩码。

$$\begin{aligned}\text{GELU}(x) &= \mathbb{E}[mx] = x\Phi(x) \\ &= \frac{x}{2}\left[1 + \text{erf}\left(\frac{x}{\sqrt{2}}\right)\right]\end{aligned}$$

erf 为误差函数；Φ(x) 把输入大小映射为连续的保留权重。

方法 • 实验

图 1 • 与常见激活函数的形状比较

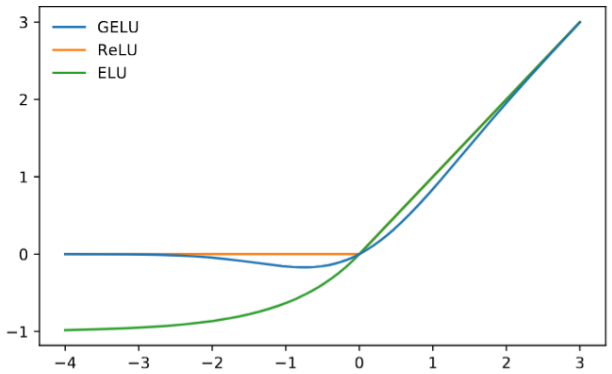


Figure 1: The GELU ($\mu = 0, \sigma = 1$), ReLU, and ELU ($\alpha = 1$).

GELU、ReLU 与 ELU；标准 GELU 使用 μ=0、σ=1。

GELU 非凸、非单调，可输出正值和负值，正半轴也有曲率。作者认为这些性质可能有助于逼近复杂函数，但没有给出该机制的因果证明。

实际计算：用近似换取速度

论文给出 tanh 与 sigmoid 两种近似。**全部实验使用 tanh 近似**；作者建议搭配带动量的优化器，并重视正态 CDF 的近似精度。

$$\mathrm{GELU}(x) \approx \frac{x}{2}(1 + \tanh u),$$
$$u = \sqrt{2/\pi}\,(x + 0.044715x^3)$$

u 包含线性项和三次项；tanh(u) 近似 2Φ(x)−1。

$$\mathrm{GELU}(x) \approx x\,\sigma(1.702x)$$

此处 σ 为 logistic sigmoid，不是正态分布的标准差。

实验

比较对象为 **GELU**、**ReLU** 和 **ELU**。 正文覆盖图像分类、自编码、推文词性标注与语音帧分类；不同任务使用不同结构与训练预算，结果应在各自设置内比较。

图 2 • MNIST：收敛与 dropout

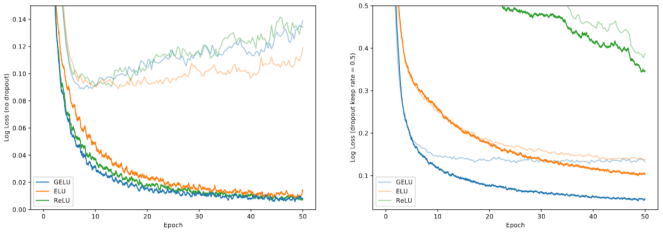


Figure 2: MNIST Classification Results. Left are the loss curves without dropout, and right are curves with a dropout rate of 0.5. Each curve is the the median of five runs. Training set log losses are the darker, lower curves, and the fainter, upper curves are the validation set log loss curves.

左：无 dropout；右：保留率 0.5。深色为训练，浅色为验证；5 次运行的中位数。

8 层、每层 128 单元，训练 50 epochs，batch=128；用 Adam，从三种学习率中选取，保留 5000 个验证样本，报告 5 次运行的中位数。

比较不使用 dropout 与保留率 0.5。GELU 通常有更低的训练损失；**训练曲线领先不能直接等同于所有验证曲线领先**。

图 3 • 输入噪声下的鲁棒性

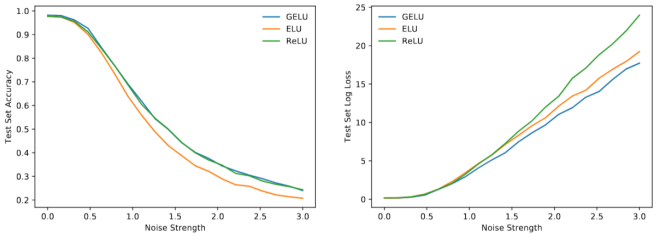


Figure 3: MNIST Robustness Results. Using different nonlinearities, we record the test set accuracy decline and log loss increase as inputs are noised. The MNIST classifier trained without dropout received inputs with uniform noise Unif$[-a, a]$ added to each example at different levels a, where $a = 3$ is the greatest noise strength. Here GELUs display robustness matching or exceeding ELUs and ReLUs.

不同均匀噪声强度下的测试准确率与对数损失。

对未使用 dropout 训练的分类器，在测试输入加入 Unif$[-a, a]$ 噪声，最高 $a = 3$。分别观察准确率下降与对数损失上升，GELU 在该设置下匹配或超过比较基线。

实验

图 4 • 自编码：重建误差

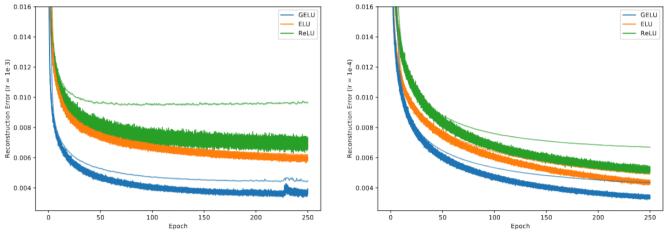


Figure 4: MNIST Autoencoding Results. Each curve is the median of three runs. Left are loss curves for a learning rate of 10^{-3}, and the right figure is for a 10^{-4} learning rate. Light, thin curves correspond to test set log losses.

两种学习率下的自编码重建曲线，3 次运行的中位数。

网络宽度依次为 1000、500、250、30、250、500、1000。使用 Adam、batch=64 和均方误差，比较 10^{-3}、10^{-4} 学习率，曲线为 3 次运行的中位数。

GELU 在两种学习率下有更低重建误差。学习率 0.01 时，ELU 发散，GELU 与 ReLU 也收敛不佳，优势仍依赖训练设置。

小样本文本：推文词性标注

25 种词性，输入为当前词及左右邻词的预训练词向量；两层各 256 单元，dropout 保留率 0.8。每种学习率运行 5 次。

测试错误率中位数：**GELU 12.57%**，ReLU 12.67%，ELU 12.91%。这里的收益幅度较小，应结合任务与基线理解。

图 5 • 语音：TIMIT 帧分类

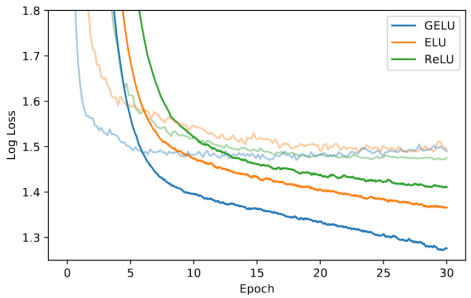


Figure 5: TIMIT Frame Classification. Learning curves show training set convergence, and the lighter curves show the validation set convergence.

TIMIT 训练与验证收敛；浅色曲线为验证集。

5 层、每层 2048 单元，39 类音素，dropout=0.5；读取 11 帧特征，预测中间帧。

按最低验证错误率选择模型，5 次运行测试错误率中位数为 **29.3% / 29.5% / 29.6%**，依次对应 GELU / ReLU / ELU。

图 6 • CIFAR-10：无数据增强

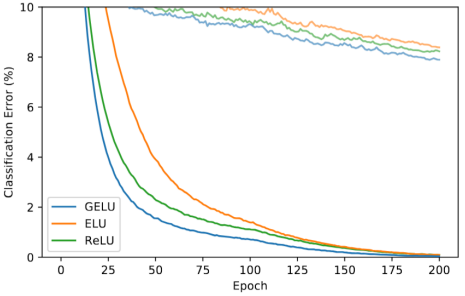


Figure 6: CIFAR-10 Results. Each curve is the median of three runs. Learning curves show training set error rates, and the lighter curves show the test set error rates.

CIFAR-10 错误率；浅色为测试集，3 次运行的中位数。

9 层卷积网络并使用 Batch Normalization，不使用数据增强。验证集选择学习率后重训全部训练集，Adam 训练 200 epochs，从第 100 个 epoch 起线性衰减学习率。

3 次运行的测试错误率中位数：**GELU 7.89%**，ReLU 8.16%，ELU 8.41%。

实验 • 局限 • 未来展望

图 7 • CIFAR-100：更深的残差网络

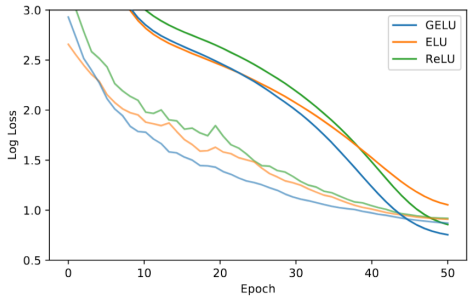


Figure 7: CIFAR-100 Wide Residual Network Results. Learning curves show training set convergence with dropout on, and the lighter curves show the test set convergence with dropout off.

CIFAR-100 对数损失；训练开启 dropout，测试关闭。

40 层、宽度倍率 4，训练 50 epochs；Nesterov 动量，dropout 保留率 0.7。为兼容 ELU，把 BatchNorm 放在残差块末尾。

修改后同一结构中，3 次运行的错误率中位数为 **20.74% / 21.77% / 22.98%**，对应 GELU / ReLU / ELU。原版 ReLU 网络的 22.89% 不应当作相同结构下的直接对照。

局限

证据支持在所测设置中有效，不能推成对所有网络与任务的保证。 比较范围、优化设置以及对机制的解释均有边界。

比较范围与结构条件

正文主要比较 ReLU、ELU，没有评估 LReLU 等更广泛的非线性；论文给出的结论应限制在已测任务和对照范围内。

CIFAR-100 为照顾 ELU 改过残差块，且各任务的预算不同。跨任务误差率、不同结构结果不能混合成一个统一的提升数字。

机制解释与经验结果要分开

曲率和非单调性“可能”改善复杂函数逼近，是作者的解释。实验证明这些配置的效果，尚不能单独确认是哪项函数性质带来收益。

近似公式存在速度与精度取舍；自编码实验中较大学习率也会带来收敛问题，GELU 不能替代对优化设置的选择。

未来展望

正文提出可以更换累积分布函数、学习正态分布参数的可能性；实际实验固定标准正态分布，没有给出独立的未来研究计划。

可探索的参数化形式

可将标准正态改成 $\mathcal{N}(\mu, \sigma^2)$，使 μ 与 σ 可学习。本文始终固定 $\mu = 0, \sigma = 1$，因此不能把可学习版本的潜力写成已验证结果。

另一个方向是替换 CDF：logistic CDF 得到 $x\sigma(x)$，文中称为 SiLU。作者在讨论中给出定性比较，但正文未提供独立的完整实验表。